

Natural Language Processing

Catedrático: Javier Josué Fong Guzmán

Estudiante: Juan Diego Letona Aguilar

Laboratorio #3

Entrega 17 de agosto, 2026



20230285

Laboratorio #3 - Clasificación de texto con Naive Bayes

I. Conjunto de entrenamiento, validación y prueba

El corpus que se mantuvo al final tuvo 1137 documentos. Se segregó de forma estratificada en 795 documentos de entrenamiento, y equitativamente 171 de validación y 171 de prueba. El entrenamiento se utilizó para aprender el modelo, validación para comparar alternativas y prueba solo para poder evaluar sobre datos no vistos y evitar el data leakage. La estratificación mantuvo prácticamente iguales las proporciones de las 7 categorías en los tres conjuntos. No se debe usar “prueba” para tomar decisiones porque dejaría de representar una evaluación realmente independiente.

Distribución porcentual de categorías			
	Entrenamiento_%	Validacion_%	Prueba_%
Type			
Macroeconomia	28.050000	28.070000	28.070000
Alianzas	21.640000	21.640000	21.640000
Innovacion	13.330000	13.450000	13.450000
Regulaciones	12.450000	12.280000	12.280000
Otra	11.320000	11.110000	11.700000
Sostenibilidad	10.940000	11.110000	10.530000
Reputacion	2.260000	2.340000	2.340000

Cantidad de documentos por categoría			
	Entrenamiento	Validacion	Prueba
Type			
Macroeconomia	223	48	48
Alianzas	172	37	37
Innovacion	106	23	23
Regulaciones	99	21	21
Otra	90	19	20
Sostenibilidad	87	19	18
Reputacion	18	4	4

II. Construcción del clasificador Naive Bayes

Se entrenaron dos clasificadores MultinomialNB, uno con bag of words y otro con TF-IDF. Los vectorizadores se ajustaron únicamente con entrenamiento mediante “fit_transform”, y por otro lado la validación y la prueba se procesaron únicamente con “transform”, evitando así el data leakage conversado en clase. Ambos vocabularios completos tuvieron 22,066 términos.

En este problema particular, $P(c)$ representa la probabilidad previa de que una noticia pertenezca a una categoría y $P(W_i|c)$ representa que tan probable es observar una palabra dentro de esa misma categoría específica. Naive Bayes combina también el prior con la evidencia aportada por las palabras y selecciona la categoría que tenga el mayor score.

III. Entrenamiento y evaluación

Los “classification_report” y las matrices de confusión fueron contruidos para ambos modelos en validación y prueba. En la prueba, el BoW obtuvo aproximadamente 80% de accuracy, mientras que por su lado TF-IDF obtuvo 55%. Ciertamente puede afirmarse que hay overfitting, especialmente en BoW, pues baja de 95% accuracy en entrenamiento a 80% en la etapa de validación, por lo que podemos decir que la generalización sobre datos nuevos es menor pero sigue siendo relativamente estable.

También puede afirmarse que el Bag of Words es un mejor predictor en este caso. Una posible explicación es que conserva directamente las frecuencias de palabras, muy apropiado para Multinomial Naive Bayes. TF-IDF reduce el peso de palabras frecuentes y en este corpus sí parece haber reducido señales que ayudaban bastante a distinguir las categorías.

	modelo	conjunto	accuracy	precision_macro	recall_macro	f1_macro	precision_ponderado	recall_ponderado	f1_ponderado
0	BoW	Entrenamiento	0.9509	0.9581	0.9240	0.9368	0.9561	0.9509	0.9512
1	BoW	Validacion	0.7953	0.8310	0.7248	0.7381	0.8070	0.7953	0.7886
2	TF-IDF	Entrenamiento	0.6881	0.7509	0.5144	0.5202	0.7942	0.6881	0.6370
3	TF-IDF	Validacion	0.5088	0.4401	0.3386	0.3246	0.5048	0.5088	0.4323
4	BoW	Prueba	0.7953	0.8331	0.7085	0.7132	0.8181	0.7953	0.7803
5	TF-IDF	Prueba	0.5497	0.2966	0.3628	0.3121	0.3992	0.5497	0.4411

IV. Análisis de errores

Las categorías que más se confundieron fueron “Alianzas” y “Otra”, con cuatro errores. Los cuatro ejemplos encontrados eran documentos de “Otra” predichos como “Alianzas”. También, entre las palabras que pudieron favorecer estas predicciones incorrectas aparecieron “programa”, “proyecto”, “desarrollo”, “educación”, “capacitación”, “alianza” y “acceso”. Para Alianzas, algunas palabras con mayor $P(W|c)$ fueron alianza, poder, país, millon, colombia y empresa. Para Otra, por su lado, destacaron bbva, banco, millón, año, financiero, entidad y crédito. Algunas sí son representativas, pero otras como año, poder o millón son muy generales y realmente podrían no brindar mucha información.

El supuesto de independencia contribuye a errores porque Naive Bayes evalúa las palabras especialmente como evidencias individuales. Una noticia podría en teoría contener términos como programa, proyecto o alianza, sin que su tema principal sea específicamente de alianzas, por ejemplo. Al sumar estas señales independientemente, el modelo puede favorecer la categoría equivocada.



V. Efecto de la representación

Reducir el vocabulario si mejoró el desempeño. El mejor fue BoW con 5000, lo que sugiere que eliminar palabras poco frecuentes redujo considerablemente el ruido sin necesariamente eliminar información útil. En tanto a los bigramas, estos no mejoraron. El vocabulario aumentó de 22,066 a 186,332, el tiempo de entrenamiento pasó aproximadamente de 0.0110 a 0.0699 segundos. Adicionalmente, accuracy y F1 macro se redujeron. Por lo tanto, podríamos argumentar que el incremento de complejidad no compenso el costo en este caso.

Se calcularon manualmente $P(c)$, $P(W_i|c)$, suavizado de Laplace y logaritmos. La implementación propia tuvo también exactamente 0.7953 de accuracy y 0.7381 de F1 macro, igual que Multinomial con el mismo BoW, y esto básicamente nos confirma que el procedimiento fundamental es el mismo.

	representacion	vocabulario	accuracy	f1_macro
0	BoW completo	22066	0.7953	0.7381
1	BoW 1000	1000	0.8304	0.8493
2	BoW 5000	5000	0.8363	0.8540
3	BoW unigramas + bigramas	186332	0.7602	0.6566
4	TF-IDF	22066	0.5088	0.3246
5	Naive Bayes propio - BoW	22066	0.7953	0.7381

VI. Otros resultados visuales



	representacion	vocabulario	accuracy	f1_macro	tiempo_entrenamiento_s
0	BoW completo	22066	0.7953	0.7381	0.0110
1	BoW unigramas + bigramas	186332	0.7602	0.6566	0.0699

VII. Análisis

1. Bayes es probabilístico porque clasifica usando $P(c)$ y $P(W_i|c)$, mientras que la similitud del coseno realmente solo mide qué tan parecidos son dos documentos. Naive Bayes aprovecha las etiquetas y también combina evidencia de muchas palabras. La similitud de coseno es útil para encontrar documentos parecidos, pero nunca garantiza que pertenezcan a la misma categoría.
2. Aunque el supuesto de independencia no es del todo realista, el modelo sí funcionó bastante bien porque muchas palabras nos brindan señales que cuando se suman como conjunto permiten ordenar correctamente las categorías. Adicionalmente, Bayes es más robusto con datos más dispersos. Esto además se alinea con los resultados porque Bag of Words tuvo buen desempeño y bag of words con 5,000 palabras tuvo incluso mejores métricas.
3. Lo más difícil fue calcular correctamente $P(W_i|c)$ junto con el suavizado, porque fue necesario contar las palabras de cada categoría y ajustar el denominador. El modelo combina el prior de cada clase con la suma de verosimilitudes de las palabras y el suavizado evita probabilidades cero mientras los logaritmos evitan problemas numéricos. Y aprendí que la implementación propia obtuvo las mismas métricas que el multinomial NB lo que es muy útil para comprobar el procedimiento.
4. Las categorías más fáciles fueron macroeconomía e innovación, mientras que "reputacion" y "otra" fueron más difíciles. Coincide parcialmente también con el lab #2 porque "Otra" ya mostraba dificultad para separarse mediante similitud de coseno. Aunque en el lab #3 su principal confusión fue con "Alianzas".
5. Validación se utilizó para comparar BoW y TF-IDF y para probar vocabularios de 1000, 5000 palabras y bigramas. La prueba se reservó para evaluar finalmente los modelos seleccionados. No deben mezclarse porque usar prueba para tomar decisiones haría que dejara de representar datos realmente desconocidos.
6. Me preocuparon categorías nuevas, cambios del vocabulario con el tiempo y clases con pocos ejemplos. Para mitigarlo actualizará periódicamente el modelo, incorpora nuevas categorías cuando aparezcan, revisará también predicciones de baja confianza y mantendría un conjunto de entrenamiento más balanceado y actualizado.

<https://github.com/JuanDi37/Lab-3---NLP>